

## §6. 解线性方程组的迭代法

### 6.1 常用迭代法

将线性方程组  $Ax = b$  等价变形为  $x = Bx + f$ ，建立迭代格式

$$x^{(k+1)} = Bx^{(k)} + f \quad (k = 0, 1, \dots)$$

其中  $B$  为迭代矩阵， $f$  是与  $A$  和  $b$  有关的向量。对方程组做不同的等价变形，将会得到不

同的迭代格式，区别仅在于迭代矩阵  $B$  和向量  $f$ 。设  $A = (a_{ij})_{n \times n}$  可分裂为

$$A = \begin{bmatrix} a_{11} & & & & \\ & a_{22} & & & \\ & & \ddots & & \\ & & & a_{nn} & \end{bmatrix} = \begin{bmatrix} 0 & & & & \\ -a_{21} & 0 & & & \\ \vdots & \vdots & \ddots & & \\ -a_{n-1,1} & -a_{n-1,2} & \cdots & 0 & \\ -a_{n1} & -a_{n2} & \cdots & -a_{n,n-1} & 0 \end{bmatrix} = \begin{bmatrix} 0 & -a_{12} & \cdots & -a_{1,n-1} & -a_{1n} \\ & 0 & \cdots & -a_{2,n-1} & -a_{2n} \\ & & \ddots & \vdots & \vdots \\ & & & 0 & -a_{n-1,n} \\ & & & & 0 \end{bmatrix} = D - L - U$$

常见的迭代格式有以下几种。

**Jacobi 迭代：** 设  $A = (a_{ij})_{n \times n}$  的主对角元素  $a_{ii} \neq 0 (i = 1, 2, \dots, n)$ ，则对角阵  $D$  可逆，分裂  $A = D - (D - A)$ ，方程组等价于

$$x = D^{-1}(D - A)x + D^{-1}b$$

令  $B_J = D^{-1}(D - A)$ ， $f_J = D^{-1}b$ ，迭代格式为  $x^{(k+1)} = B_J x^{(k)} + f_J (k = 0, 1, \dots)$ ，称为 Jacobi 迭代。

**Gauss-Seidel 迭代：** 设  $A = (a_{ij})_{n \times n}$  的主对角元素  $a_{ii} \neq 0 (i = 1, 2, \dots, n)$ ，则下三角阵  $D - L$  可逆，分裂  $A = (D - L) - U$ ，方程组等价于

$$x = (D - L)^{-1}Ux + (D - L)^{-1}b$$

令  $B_G = (D - L)^{-1}U$ ， $f_G = (D - L)^{-1}b$ ，迭代格式为  $x^{(k+1)} = B_G x^{(k)} + f_G (k = 0, 1, \dots)$ ，称为 Gauss-Seidel 迭代，也可以记为

$$Dx^{(k+1)} = Lx^{(k+1)} + Ux^{(k)} + b \quad (k = 0, 1, \dots)$$

**逐次超松弛迭代 (SOR 迭代)：** 设  $A = (a_{ij})_{n \times n}$  的主对角元素  $a_{ii} \neq 0 (i = 1, 2, \dots, n)$ ，分裂  $\omega A = (D - \omega L) - ((1 - \omega)D + \omega U)$ ，其中  $\omega$  为选定的非零参数，方程组  $Ax = b$  等价于

$$(D - \omega L)x = ((1 - \omega)D + \omega U)x + \omega b$$

令  $B = (D - \omega L)^{-1}((1 - \omega)D + \omega U)$ ,  $f = \omega(D - \omega L)^{-1}b$ , 迭代格式为

$$x^{(k+1)} = Bx^{(k)} + f \quad (k = 0, 1, \dots),$$

称为逐次超松弛迭代, 其中  $\omega$  为松弛因子, 也称 SOR 迭代。迭代格式还可以改写为

$$Dx^{(k+1)} = Dx^{(k)} + \omega(Lx^{(k+1)} + Ux^{(k)} - Dx^{(k)} + b) \quad (k = 0, 1, \dots)$$

Matlab 代码如下:

```
function [x,n]=SOR(A,b,x0,w,eps,M)
%--SOR迭代法解线性方程组
if nargin==4
    eps= 1.0e-6;
    M = 10000;
elseif nargin<4
    error
    return
elseif nargin ==5
    M = 10000;
end

if(w<=0 || w>=2)
    error;
    return;
end
D=diag(diag(A));
L=-tril(A,-1);
U=-triu(A,1);
B=inv(D-L*w)*((1-w)*D+w*U);
f=w*inv((D-L*w))*b;
x=B*x0+f;
n=1;
while norm(x-x0)>=eps
    x0=x;
    x =B*x0+f;
    n=n+1;
    if(n>=M)
        disp('Warning: 迭代次数太多, 可能不收敛');
        return;
    end
end
end
```

## 6.2 共轭梯度法

已知线性方程组  $Ax = b$  中的系数矩阵  $A$  为实对称正定阵，则求解方程组的真实解  $x^*$

等价于求泛函  $\varphi(x) = \frac{1}{2}(Ax, x) - (b, x)$  的极小值点  $x^*$ ，求解方法是构造一个向量序列  $\{x^{(k)}\}$

使  $\varphi(x^{(k)}) \rightarrow \varphi(x^*)$ 。通常的解法是从初始向量  $x^{(0)}$  出发，找一个方向  $p^{(0)}$ ，令

$x^{(1)} = x^{(0)} + \alpha_0 p^{(0)}$ ，使  $\varphi(x^{(1)}) = \min_{\alpha \in R} (x^{(0)} + \alpha p^{(0)})$ 。一般的，令  $x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)}$ ，使

$$\varphi(x^{(k+1)}) = \min_{\alpha \in R} (x^{(k)} + \alpha p^{(k)})$$

由此得出  $\alpha_k = \frac{(r^{(k)}, p^{(k)})}{(p^{(k)}, Ap^{(k)})}$ 。根据不同的方向  $p^{(k)}$ ，可以有不同的迭代格式。

一般的有，选取方向  $p^{(k)}$  使  $\varphi(x)$  在点  $x^{(k)}$  沿  $p^{(k)}$  下降最快，即为  $\varphi(x)$  在  $x^{(k)}$  的负梯度方向

$$p^{(k)} = -\nabla \varphi(x^{(k)}) = -(Ax^{(k)} - b) = r^{(k)}$$

则  $\alpha_k = \frac{(r^{(k)}, r^{(k)})}{(r^{(k)}, Ar^{(k)})}$ ，于是建立求  $\varphi(x)$  的极小值点  $x^*$  的最速下降法：任取  $x^{(0)} \in R^n$ ，

$$\begin{cases} r^{(k)} = b - Ax^{(k)}, \alpha_k = \frac{(r^{(k)}, r^{(k)})}{(r^{(k)}, Ar^{(k)})} \\ x^{(k+1)} = x^{(k)} + \alpha_k r^{(k)} \quad (k = 0, 1, 2, \dots) \end{cases}$$

在最速下降法中，当  $r^{(k)}$  较小时，由于舍入误差的影响，实际计算的  $r^{(k)}$  会偏离最速下降方向，则选取方向向量  $p^{(k)}$  为

$$\begin{cases} p^{(0)} = r^{(0)} \\ p^{(k)} = r^{(k)} + \beta_k p^{(k-1)} \quad (k = 1, 2, \dots) \end{cases}$$

并要求  $[p^{(k)}, Ap^{(k-1)}] = 0$ ，即相邻两步的方向向量关于矩阵  $A$  共轭，可得到

$$\beta_k = -\frac{(r^{(k)}, Ap^{(k-1)})}{(p^{(k-1)}, Ap^{(k-1)})}$$

于是建立求  $\varphi(x)$  的极小值点  $x^*$  的共轭梯度法。任取  $x^{(0)} \in R^n$ ，

$$\begin{cases} r^{(k)} = b - Ax^{(k)}, \beta_k = -\frac{(r^{(k)}, Ap^{(k-1)})}{(p^{(k-1)}, Ap^{(k-1)})} = \frac{(r^{(k)}, r^{(k-1)})}{(r^{(k-1)}, r^{(k-1)})} \\ p^{(k)} = r^{(k)} + \beta_k p^{(k-1)}, \alpha_k = \frac{(r^{(k)}, p^{(k)})}{(p^{(k)}, Ap^{(k)})} = \frac{(r^{(k)}, r^{(k)})}{(p^{(k)}, Ap^{(k)})} \\ x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)} \quad (k=1, 2, \dots) \end{cases}$$

## §7. 非线性方程的数值解法

### 7.1 不动点迭代法

将方程  $f(x)=0$  改写为等价形式  $x=\varphi(x)$ ，若  $x^*$  满足  $f(x^*)=0$ ，则  $x^*=\varphi(x^*)$ ，则称  $x^*$  为  $\varphi(x)$  的一个不动点，求  $f(x)$  的零点等价于求  $\varphi(x)$  的不动点。对于初始近似值  $x_0 \in [a, b]$ ，构造迭代格式

$$x_{k+1} = \varphi(x_k) \quad (k=0, 1, 2, \dots)$$

若得到的点列  $\{x_k\}$  有  $\lim_{k \rightarrow \infty} x_k = x^*$ ，则迭代收敛，且  $x^*$  为  $\varphi(x)$  的不动点，上述迭代格式称为不动点迭代。

如果把 Aitken 加速和不动点迭代结合，可得到

$$\begin{cases} y_k = \varphi(x_k), z_k = \varphi(y_k) \\ x_{k+1} = x_k - \frac{(y_k - x_k)^2}{z_k - 2y_k + x_k} \quad (k=0, 1, 2, \dots) \end{cases}$$

称为 Steffensen 迭代法。

Matlab 代码如下：

```
function [root,n]=SteffenStablePoint(g,x0,eps)
%--Steffensen迭代, g为不动点迭代的迭代函数
if nargin==2
    eps=1.0e-4;
end
```

```

tol=1;
root=x0;
n=0;
while (tol>eps)
    n=n+1;
    r1=root;
    y=subs(sym(g),findsym(sym(g)),r1)+r1;
    z=subs(sym(g),findsym(sym(g)),y)+y;
    root=r1-(y-r1)^2/(z-2*y+r1);
    tol=abs(root-r1);
end

```

## 7.2 Newton 法

设已知方程  $f(x) = 0$  有近似根  $x_k$  (假定  $f'(x_k) \neq 0$ )，将函数  $f(x)$  在点  $x_k$  展开，

$$f(x) \approx f(x_k) + f'(x_k)(x - x_k)$$

也是方程  $f(x) = 0$  可近似的表示为

$$f(x_k) + f'(x_k)(x - x_k) = 0$$

这是个线性方程，其根记为  $x_{k+1}$ ，则  $x_{k+1}$  的计算公式为

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)} (k = 0, 1, 2, \dots)$$

这就是 Newton 法。

为了防止迭代发散，将 Newton 法与下山法结合起来，即在下山法保证函数稳定下降的前提下，用 Newton 法加快收敛速度，将 Newton 法的结果  $\bar{x}_{k+1} = x_k - f(x_k)/f'(x_k)$  与前一步的近似值  $x_k$  适当加权平均作为新的改进值  $x_{k+1} = \lambda \bar{x}_{k+1} + (1 - \lambda)x_k$ ，其中  $\lambda (0 < \lambda \leq 1)$  为下山因子，

$$x_{k+1} = x_k - \lambda \frac{f(x_k)}{f'(x_k)} (k = 0, 1, 2, \dots)$$

称为 Newton 下山法。选择  $\lambda$  时，从  $\lambda = 1$  开始，逐次将  $\lambda$  减半进行，直到满足下降条件

$|f(x_{k+1})| < |f(x_k)|$  为止。

Matlab 代码如下：

```

function root=NewtonDown(f,a,b,x0,eps)
%--Newton下山法
if(nargin==3)
    eps=1.0e-4;
end
fa=subs(sym(f),findsym(sym(f)),a);
fb=subs(sym(f),findsym(sym(f)),b);
if(fa==0)
    root=a;
end
if(fb==0)
    root=b;
end
if(fa*fb>0)
    disp('两端点函数值乘积大于0!');
    return;
else
    tol=1;
    fun=diff(sym(f));
    root=x0;
    while(tol>eps)
        r1=root;
        fx=subs(sym(f),findsym(sym(f)),r1);
        dfx=subs(sym(fun),findsym(sym(fun)),r1);
        toldf=1;
        lamda=2;
        while toldf>0
            lamda=lamda/2;
            root=r1-lamda*fx/dfx;
            fv=subs(sym(f),findsym(sym(f)),root);
            toldf=abs(fv)-abs(fx);
        end
        tol=abs(root-r1);
    end
end
end

```

## §9. 常微分方程的初值问题

## 9.1 Euler 法

一阶常微分方程的初值问题

$$\begin{cases} y' = f(x, y), x \in [x_0, b] \\ y(x_0) = y_0 \end{cases}$$

的解  $y = y(x)$  称作它的积分曲线，积分曲线上一点  $(x, y)$  的切线斜率等于函数  $f(x, y)$  的值。如果按函数  $f(x, y)$  在  $xy$  平面上建立一个方向场，积分曲线上每一点的切线方向均与方向场在该点的方向一致。一般的，从初始点  $P_0(x_0, y_0)$  依方向场在该点的方向推进到  $x = x_1$  上的一点  $P_1(x_1, y_1)$ ，再重复上述步骤，作出一条折线  $\overline{P_0 P_1 P_2 \cdots}$ 。而折线上的两个顶点

$P_n(x_n, y_n)$  和  $P_{n+1}(x_{n+1}, y_{n+1})$  的坐标满足  $(y_{n+1} - y_n)/(x_{n+1} - x_n) = f(x_n, y_n)$ ，即

$$y_{n+1} = y_n + hf(x_n, y_n)$$

上述方法称为 Euler 法。

Matlab 代码如下：

```
function y = DEEuler(f, h, x0, b, y0, varvec)
format long;
N = (b-x0)/h;
y = zeros(N+1,1);
x = x0:h:b;
y(1) = y0;
for i=2:N+1
    y(i) = y(i-1)+h*Funval(f,varvec,[x(i-1), y(i-1)]);
end
format short;
function fv = Funval(f,varvec,varval)
var = findsym(f);
if length(var) > 4
    if var(1) == varvec(1)
        fv = subs(f,varvec(1),varval(1));
    else
        fv = subs(f,varvec(2),varval(2));
    end
else
    fv = subs(f,varvec,varval);
end
```

## 9.2 Runge-Kutta 方法

由 Euler 法和改进的 Euler 法，可总结类似的公式

$$y_{n+1} = y_n + h\varphi(x_n, y_n, h)$$

其中  $\varphi(x_n, y_n, h)$  为增量函数，表达式为

$$\begin{cases} \varphi(x_n, y_n, h) = \sum_{i=1}^r c_i K_i \\ K_1 = f(x_n, y_n) \\ K_i = f(x_n + \lambda_i h, y_n + h \sum_{j=1}^{i-1} \mu_{ij} K_j) (i = 2, \dots, r) \end{cases}$$

这里  $c_i, \lambda_i, \mu_{ij}$  均为常数，上两式合称为  $r$  级显式 Runge-Kutta 法，精度记为  $p$  阶。

当  $r = 1$  时， $\varphi(x_n, y_n, h) = f(x_n, y_n)$ ，就是 Euler 法，此时方法的阶为  $p = 1$ 。当  $r = 2$

时，改进的 Euler 法公式就是其中一种，常用的计算公式还有中点方法，方法的阶均为  $p = 2$ 。

中点方法 Matlab 代码如下：

```
function y = RungeKutta2_mid(f,h,a,b,y0,varvec)
format long;
N = (b-a)/h;
y = zeros(N+1,1);
y(1) = y0;
x = a:h:b;
var = findsym(f);
for i=2:N+1
    K1 = Funval(f,varvec,[x(i-1) y(i-1)]);
    t = y(i-1) + h*K1/2;
    K2 = Funval(f,varvec,[x(i)+h/2 t]);
    y(i) = y(i-1)+h*K2;
end
format short;
```

常用的三阶 Runge-Kutta 公式有：

$$\begin{cases} y_{n+1} = y_n + \frac{h}{6}(K_1 + 4K_2 + K_3) \\ K_1 = f(x_n, y_n) \\ K_2 = f(x_n + \frac{h}{2}, y_n + \frac{h}{2}K_1) \\ K_3 = f(x_n + h, y_n - hK_1 + 2hK_2) \end{cases}$$



Matlab 代码如下:

```
function y = RungeKutta3(f, h,a,b,y0,varvec)
format long;
N = (b-a)/h;
y = zeros(N+1,1);
y(1) = y0;
x = a:h:b;
var = findsym(f);
for i=2:N+1
    K1 = Funval(f,varvec,[x(i-1) y(i-1)]);
    K2 = Funval(f,varvec,[x(i-1)+h/2 y(i-1)+K1*h/2]);
    K3 = Funval(f,varvec,[x(i-1)+h y(i-1)-h*K1+K2*2*h]);
    y(i) = y(i-1)+h*(K1+4*K2+K3)/6;
end
format short;
```

常用的还有经典四阶 Runge-Kutta 公式:

$$\begin{cases} y_{n+1} = y_n + \frac{h}{6}(K_1 + 2K_2 + 2K_3 + K_4) \\ K_1 = f(x_n, y_n) \\ K_2 = f(x_n + \frac{h}{2}, y_n + \frac{h}{2}K_1) \\ K_3 = f(x_n + \frac{h}{2}, y_n + \frac{h}{2}K_2) \\ K_4 = f(x_n + h, y_n + hK_2) \end{cases}$$